

JiuwenSwarm v4: Agent 自我进化

JiuwenSwarm/UCR 可审计科研半流程

1 重要边界

本文是 v4 LaTeX 源文件；配套正式 PDF 已由本机使用 XeLaTeX 编译。UCR 标签为 `process_evidence_only`，只能证明流程证据能力，不能包装成领域科学结论。claim-018 至 claim-020 及其绑定来源已批准正式引用，其余未批准来源仍排除。

2 研究问题与计划

问题：带证据的反思循环能否避免把未执行任务写成已完成？

假设：证据检查可能改善审计表达，但当前基准不证明真实自我进化。

- 每个结论均可追溯到具体实验臂的决策记录。
- UCR 仅作为过程证据指标报告，不解释为能力或进化证据。
- 任务成功率与 UCR 分开报告，避免混淆。
- 若证据不足，明确标注 `indeterminate` 或 `not_measured`。

3 方法

对每个操作记录证据匹配结果,标注 `supported`、`unexecuted` 或 `indeterminate`;UCR 定义为 `unexecuted` 决策数除以总决策数。比较三臂 UCR 与任务成功率，检查证据检查是否降低未执行任务被写成已完成的情况。

3.1 实验设置

三个实验臂：`no-rail`（护栏未启用，9 个决策）、`prompt-only`（护栏未启用，4 个决策）、`full-rail`（护栏启用 1 次且被接受，4 个决策）。CFR 与 NFR 在 UCR 场景中未测量。

Arm	状态	UCR	Supported
no-rail	completed	0.5556	4
prompt-only	completed	0.0	4
full-rail	completed	0.0	4

4 实验结果

`no-rail`: UCR=0.5556 (5 / 9), supported=4, unexecuted=5, 任务成功率 =1.0。`prompt-only`: UCR=0.0 (0 / 4), supported=4, unexecuted=0, 任务成功率 =1.0。`full-rail`: UCR=0.0 (0 / 4), supported=4,

unexecuted=0，任务成功率 =1.0，护栏启用 1 次且被接受。

5 Claim–Evidence 账本

Claim ID	状态	类型
claim-001	supported	experiment_observation
claim-002	pending_human_review	experiment_observation
claim-003	pending_human_review	experiment_observation
claim-004	supported	experiment_observation
claim-005	pending_human_review	experiment_observation
claim-006	supported	experiment_observation
claim-007	pending_human_review	experiment_observation
claim-008	supported	experiment_observation
claim-009	pending_human_review	experiment_observation
claim-010	supported	experiment_observation
claim-011	supported	experiment_observation
claim-012	supported	experiment_observation
claim-013	supported	experiment_observation
claim-014	supported	experiment_observation
claim-015	supported	experiment_observation
claim-016	supported	experiment_observation
claim-017	supported	experiment_observation
claim-018	supported	background
claim-019	supported	background
claim-020	supported	background

6 检索资料与人工审批

候选资料数：10。只有人工批准后才允许正式引用。

Source ID	relevance review
crossref:10.1115 / detc2025-168710	0.07 approved
openalex:W2508346077	0.02 approved
openalex:W2903899730	0.02 approved
openalex:W2048701323	0.02 pending
openalex:W607740409	0.02 pending
openalex:W2153791616	0.02 pending
openalex:W2316973238	0.02 pending

Source ID	relevance	review
openalex:W2109120348	0.02	pending
openalex:W1979058254	0.02	pending
openalex:W2112351720	0.02	pending

7 限制

UCR 仅为过程证据指标，不能解释为能力或真实自我进化证据。CFR 与 NFR 未测量。已批准的三条背景来源可正式引用，其余来源仍被排除。当前基准是否足以回答研究问题需结合五条明确排除的失败 Claim 判断。

不支持 Claim: claim-002, claim-003, claim-005, claim-007, claim-009

8 结论

在本次基准中，prompt-only 与 full-rail 的 UCR 均为 0.0，no-rail 为 0.5556，提示证据检查可能改善审计表达；但任务成功率三臂均为 1.0，且 CFR / NFR 未测量，因此当前结果不证明真实自我进化。

9 人工确认

研究问题、实验真实性、结论范围和最终提交都需要人工确认。