

JiuwenSwarm v4: Agent 上下文工程

JiuwenSwarm/UCR 可审计科研半流程

1 重要边界

本文是 v4 LaTeX 源文件；配套正式 PDF 已由用户在本机使用 XeLaTeX 编译。UCR 标签为 `process_evidence_only`，只能证明流程证据能力，不能包装成领域科学结论。检索资料默认等待人工审批，最终研究问题、实验真实性、结论范围和提交资格仍需人工确认。

2 研究问题与计划

问题：程序级证据护栏能否提高 Agent 执行报告的证据一致性？

假设：full-rail 应比无护栏或仅提示词减少无证据完成声明。

- full-rail 的 UCR 低于 no-rail。
- full-rail 的 UCR 不高于 prompt-only。
- 所有结论仅基于已提供的 `experiment_summary`，不引入外部证据。

3 方法

复用已完成的三个 arm 结果，不新增实验。以 UCR (unsupported completion rate) 为主指标，比较 no-rail、prompt-only、full-rail 的 UCR 差异，并记录 rail 启用与接受情况。所有结论仅基于提供的 `experiment_summary`。

3.1 实验设置

三个 arm: no-rail (`rail.enabled=false, attempts=0, accepted=true`)、prompt-only (`rail.enabled=false, attempts=0, accepted=true`)、full-rail (`rail.enabled=true, attempts=1, accepted=true`)。每个 arm 的 `return_code=0, status=completed`。UCR 为 `process_evidence_only` 指标。CFR 与 NFR 在 UCR 场景中未测量。

Arm	状态	UCR	Supported
no-rail	completed	0.5556	4
prompt-only	completed	0.0	4
full-rail	completed	0.0	4

4 实验结果

no-rail: UCR=0.5556 (5 / 9), supported=4, unexecuted=5, task_success_rate=1.0。prompt-only: UCR=0.0 (0 / 4), supported=4, unexecuted=0, task_success_rate=1.0。full-rail: UCR=0.0 (0 / 4), supported=4, unexecuted=0, task_success_rate=1.0, rail.enabled=true, attempts=1, accepted=true。full-rail 的 UCR 低于 no-rail, 且不高于 prompt-only。

5 Claim–Evidence 账本

Claim ID	状态	类型
claim-001	supported	experiment_observation
claim-002	pending_human_review	experiment_observation
claim-003	pending_human_review	experiment_observation
claim-004	supported	experiment_observation
claim-005	pending_human_review	experiment_observation
claim-006	supported	experiment_observation
claim-007	pending_human_review	experiment_observation
claim-008	supported	experiment_observation
claim-009	pending_human_review	experiment_observation
claim-010	supported	experiment_observation
claim-011	supported	experiment_observation
claim-012	supported	experiment_observation
claim-013	supported	experiment_observation
claim-014	supported	experiment_observation
claim-015	supported	experiment_observation
claim-016	supported	experiment_observation
claim-017	supported	experiment_observation
claim-018	pending_human_review	background
claim-019	pending_human_review	background
claim-020	pending_human_review	background

6 检索资料与人工审批

候选资料数：10。只有人工批准后才允许正式引用。

Source ID	relevance review
crossref:10.2139 / ssrn.6506600	0.07 pending
crossref:10.37547 / tajar / volume08issue03-12	0.07 pending
crossref:10.4018 / 978-1-60566-618-1.ch002	0.07 pending

Source ID	relevance	review
openalex:W3109746568	0.02	pending
openalex:W2165744313	0.02	pending
openalex:W2139457077	0.02	pending
openalex:W2153791616	0.02	pending
openalex:W2167554769	0.02	pending
openalex:W2124405605	0.02	pending
openalex:W2115421876	0.02	pending

7 限制

UCR 仅作为 process_evidence_only 指标，不能外推为任务质量或真实完成率。CFR 与 NFR 在 UCR 场景中未测量，不应报告为结果。citation_allowed=false 的材料不得作为正式引用。citation_coverage=0.0, allow_paper=false。当前证据仅支持有限结论：full-rail 与 prompt-only 均未出现无证据完成声明。不支持 Claim: claim-002, claim-003, claim-005, claim-007, claim-009, claim-018, claim-019, claim-020

8 结论

在已提供的实验数据范围内，full-rail 的 UCR (0.0) 低于 no-rail (0.5556)，且不高于 prompt-only (0.0)。该结果与假设方向一致，但受限于 UCR 仅为过程证据指标，不能推断任务质量或真实完成率。需人工确认是否接受该有限结论。

9 人工确认

研究问题、实验真实性、结论范围和最终提交都需要人工确认。