

# JiuwenSwarm v4 可审计科研论文半流程报告

JiuwenSwarm/UCR

## 摘要

本文汇总三个主题的科研半流程演示。系统检索公开资料元数据，执行 JiuwenSwarm/UCR 本地证据实验，生成研究计划和报告，并保存 Claim-Evidence 账本。本文不把流程基准包装成领域科学结论；正式引用、实验真实性、研究结论和最终提交资格仍需人工确认。

## 1 统一边界

UCR 的标签是 `process_evidence_only`，它表示系统的流程证据和审计能力，不等于上下文工程、记忆引擎或自我进化的领域效果。所有来源默认处于待审核状态。当前 PDF 是由本机 XeLaTeX 编译生成的正式查看产物，源文件和实验记录同时保留在提交包中。

## 2 矩阵概览

| 主题                  | 状态                             | Provider 调用 |
|---------------------|--------------------------------|-------------|
| context-engineering | completed_pending_human_review | 3           |
| memory-engine       | completed_pending_human_review | 3           |
| self-evolution      | completed_pending_human_review | 3           |

## 3 Agent 上下文工程

**摘要：**本报告检验程序级证据护栏能否提高 Agent 执行报告的证据一致性。基于已完成的 no-rail、prompt-only、full-rail 三个 arm 的 UCR 指标，no-rail 的 UCR 为 0.5556 (5 / 9)，prompt-only 与 full-rail 均为 0.0 (0 / 4)。full-rail 的 rail.enabled=true、attempts=1、accepted=true。三个 arm 的 task\_success\_rate 均为 1.0。证据仅支持有限结论：full-rail 与 prompt-only 均未出现无证据完成声明，且 full-rail 的 UCR 低于 no-rail。

**结论：**在已提供的实验数据范围内，full-rail 的 UCR (0.0) 低于 no-rail (0.5556)，且不高于 prompt-only (0.0)。该结果与假设方向一致，但受限于 UCR 仅为过程证据指标，不能推断任务质量或真实完成率。需人工确认是否接受该有限结论。

**限制：**UCR 仅作为 process\_evidence\_only 指标，不能外推为任务质量或真实完成率。CFR 与 NFR 在 UCR 场景中未测量，不应报告为结果。citation\_allowed=false 的材料不得作为正式引用。citation\_coverage=0.0，allow\_paper=false。当前证据仅支持有限结论：full-rail 与 prompt-only 均未出现无证据完成声明。

## 4 Agent 记忆引擎

**摘要：**本报告检验结构化记忆记录是否有助于 Agent 保持审计上下文一致。三组已完成运行（no-rail、prompt-only、full-rail）均 return\_code=0, task\_success\_rate=1.0。UCR 仅作为过程证据：no-rail=0.5556（5 / 9），prompt-only=0.0（0 / 4），full-rail=0.0（0 / 4）。CFR 与 NFR 未测量。材料最高 relevance\_score=0.32 且 citation\_allowed=false，不构成正式引用。

**结论：**当前基准仅支持过程可追溯性观察：三组任务成功率均为 1.0，但 UCR 在 no-rail 为 0.5556、prompt-only 与 full-rail 均为 0.0，且 full-rail 的 rail\_attempts=1、accepted=true。该结果不足以支持结构化记忆记录改善领域效果的结论。所有结论需标注 claim\_id 与证据来源，citation\_allowed=false 来源不得正式引用。

**限制：**UCR 为 process\_evidence\_only，不能证明领域效果。CFR 与 NFR 未测量，不纳入结论。材料 relevance\_score 最高 0.32 且 citation\_allowed=false，不得正式引用（claim-018 至 claim-020 待人工复核）。no-rail 中 run\_failed、run\_denied、inspect\_missing、query\_unavailable、validate\_failed 为 unexecuted，对应 claim-002、claim-003、claim-005、claim-007、claim-009 待人工复核。citation\_coverage=0.0，allow\_paper=false，human\_intervention\_required=true。

## 5 Agent 自我进化

**摘要：**本报告检验带证据的反思循环能否避免把未执行任务写成已完成。在相同任务集上比较 no-rail、prompt-only、full-rail 三个实验臂，以 UCR（未执行却写成已完成的比例）作为过程证据。no-rail 的 UCR=0.5556（5 / 9），prompt-only 与 full-rail 的 UCR=0.0（0 / 4）。所有臂任务成功率均为 1.0。结果仅支持审计表达层面的改善，不证明真实自我进化。

**结论：**在本次基准中，带证据的反思循环与仅提示均将 UCR 从 no-rail 的 0.5556 降至 0.0，说明证据检查可能改善审计表达（claim-001 至 claim-017 支持相应操作状态）。但该结果仅限过程证据，不证明真实自我进化；需人工确认 UCR 的解释边界及待审背景声明。

**限制：**UCR 仅为过程证据，不能解释为真实自我进化。CFR 与 NFR 在 UCR 场景中未测量。citation\_coverage=0.0，citation\_allowed=false 的材料不得作为正式引用。claim-002、claim-003、claim-005、claim-007、claim-009、claim-018、claim-019、claim-020 仍待人工审查。当前基准不足以证明真实自我进化。

## 6 编译与审核说明

该统一报告和三个主题报告都需要人工阅读。编译命令为：

```
xelatex -interaction=nonstopmode -halt-on-error paper.tex
xelatex -interaction=nonstopmode -halt-on-error paper.tex
```

最终状态保持为 prepared\_not\_uploaded。