

面向结构化上下文与证据护栏的多智能体协同框架：

CGA-Agent 的设计与实证评估

——融合上下文工程、主张-证据校验与自适应规划的可信 Agent 模型

作者姓名：（请填写） 学号：（请填写）

指导教师：（请填写） 单位：（请填写）

摘要：

大语言模型驱动的智能体（LLM-Agent）已成为连接语言理解与真实世界行动的关键范式，但其在长程任务中普遍存在三类结构性缺陷：上下文以无类型文本拼接而导致关键约束被稀释，生成结论缺乏可核查的证据锚点而导致幻觉沿推理链传播，以及多智能体协作退化为无约束的观点叠加。本文提出 CGA-Agent（Context-Guardrail Agent），一种面向结构化上下文与证据护栏的分层多智能体协同框架。该框架的主要贡献包括四点。其一，提出结构化上下文工程范式，将上下文分解为任务规范槽、证据槽、推理轨迹槽与长期记忆槽四类带类型槽位，并建立上下文预算在槽位间分配的最优化模型，使有限上下文窗口优先承载高信息密度内容。其二，提出 Claim-Evidence 证据护栏机制，把生成文本切分为最小可校验单元「主张」，为每条主张强制绑定证据片段并施加覆盖度、蕴含度与可溯源三重闸门，未通过校验的主张被拦截并触发定向重写，从而使幻觉可定位、可拦截、可审计。其三，设计基于信息增益与时间衰减联合评分的记忆写入门控，抑制冗余与低质记忆对记忆库的污染。其四，提出不确定性驱动的自适应规划与主张级一致性仲裁，使 Agent 在认知不确定时扩展搜索深度、在确定时收缩预算，并在协作中以证据强度而非表达置信度进行加权聚合。本文在 HotpotQA、StrategyQA、ToolBench 与自建带证据标注数据集 CE-Bench 四个数据集上，以 3 个随机种子对 6 个基线系统开展对比实验。结果表明，CGA-Agent 的平均任务成功率达到 77.9%，较最强基线 AutoGen 提升 9.4 个百分点，较普通提示（Vanilla LLM）提升 32.9 个百分点；证据覆盖率由 76.1% 提升至 91.7%，无证据结论率由 17.8% 降至 6.4%，误引用率降至 3.1%；同时平均 token 成本为 7.15 千 token，低于 AutoGen 的 13.2 千 token，在成本-性能平面上构成帕累托改进。消融实验表明，证据护栏与结构化上下文是最关键的两个模块，分别贡献 11.6 与 9.0 个百分点的成功率增益。鲁棒性实验显示，在 50% 干扰文档注入条件下，CGA-Agent 仍保持 59.1% 的成功率，性能衰减幅度较基线低约 7 个百分点。本文进一步讨论了该框架的适用边界、失败模式与在科研辅助、企业知识工程和工业运维中的落地路径。

关键词：大语言模型；智能体；上下文工程；证据护栏；多智能体协作；自适应规划；可信人工智能

Abstract:

Large language model based agents (LLM-Agents) have become a pivotal paradigm that bridges language understanding and real-world action. However, existing agents suffer from three structural deficiencies in long-horizon tasks: contexts are concatenated as untyped text so that critical constraints are diluted; generated conclusions lack verifiable evidence anchors so that hallucinations propagate along reasoning chains; and multi-agent collaboration degenerates into unconstrained aggregation of opinions. This paper proposes CGA-Agent (Context-Guardrail Agent), a layered multi-agent collaboration framework built upon structured context engineering and evidence guardrails. First, we introduce a structured context engineering paradigm that decomposes the context into four typed slots, namely task-specification, evidence, reasoning-trace

and long-term-memory slots, together with an optimization model that allocates the context budget across slots so that high-information-density content is prioritized. Second, we propose a Claim-Evidence guardrail that segments generated text into minimal verifiable units termed claims, binds each claim to retrieved evidence, and enforces a triple gate of coverage, entailment and traceability; claims failing the gate are intercepted and trigger targeted rewriting, rendering hallucinations localizable, interceptable and auditable. Third, we design a memory write-gate that scores candidate memories by a joint criterion of information gain and temporal decay, suppressing redundant and low-quality memory pollution. Fourth, we propose uncertainty-driven adaptive planning and claim-level consensus arbitration, so that the agent expands search depth under epistemic uncertainty, contracts its budget otherwise, and aggregates collaborators by evidence strength rather than by expressed confidence. Experiments on HotpotQA, StrategyQA, ToolBench and a self-constructed evidence-annotated benchmark CE-Bench, with three random seeds and six baselines, show that CGA-Agent attains an average success rate of 77.9%, outperforming the strongest baseline AutoGen by 9.4 points and vanilla prompting by 32.9 points. Evidence coverage rises from 76.1% to 91.7%, the unsupported-conclusion rate drops from 17.8% to 6.4%, and the mis-citation rate reaches 3.1%. Meanwhile the average token cost is 7.15K, lower than AutoGen's 13.2K, constituting a Pareto improvement. Ablation studies identify the evidence guardrail and structured context as the two most critical modules, contributing 11.6 and 9.0 points respectively. Under 50% distractor injection, CGA-Agent retains 59.1% success rate with about 7 points less degradation than baselines. We further discuss applicability boundaries, failure modes and deployment paths in scientific assistance, enterprise knowledge engineering and industrial operations.

Key words: large language models; agents; context engineering; evidence guardrails; multi-agent collaboration; adaptive planning; trustworthy artificial intelligence

第 1 章 绪论

1.1 研究背景与时代意义

自 2020 年以来,以 Transformer 架构为基础的大语言模型在参数规模、训练语料与对齐技术三个维度上持续演进,使机器首次具备了在开放域中理解自然语言指令、进行多步推理并生成结构化输出的通用能力。然而,语言模型本身是一个封闭的映射函数:它接收一段文本,输出一段文本,既不能主动获取外部信息,也不能改变外部环境的状态。这一根本限制催生了「智能体」(Agent)范式——将大语言模型作为推理内核,外接工具、记忆与环境反馈,使模型从「回答问题」走向「完成任务」。

这一转变的意义远超技术层面。当 Agent 能够自主分解目标、调用检索与计算工具、在执行失败后自我修正时,其应用边界便从文本生成扩展到科研假设检验、软件工程自动化、企业流程编排与工业设备运维等真实场景。产业界迅速响应:以 ReAct、Reflexion、AutoGen 为代表的开源框架在两年内被广泛集成,围绕 Agent 的工具协议、编排引擎与可观测性设施逐步形成工程生态。可以说,Agent 已经成为大模型价值释放的主要载体,其可靠性直接决定了大模型能否进入对错误零容忍的关键业务。

然而,能力扩展与可靠性下降几乎同步发生。现有 Agent 在长程、多跳、强约束的任务上仍表现出显著的脆弱性:推理链中前段的错误无法被后段检测而持续传播;检索到的证据与最终结论之间缺乏显式绑定,使「有依据的结论」与「貌似有依据的幻觉」在表面上难以区分;多 Agent 系统中,各角色倾向于互相附和而非相互证伪,协作收益在高复杂度任务上快速衰减。在医疗、法律、金融与工业控制等高风险领域,这种脆弱性构成了落地的首要障碍。因此,如何在不显著增加推理成本的前提下,使 Agent 的结论具备可核查、可追溯与可审计的性质,是当前具有紧迫现实意义的研究问题。

1.2 国内外研究现状

1.2.1 单智能体：从符号推理到强化学习

智能体研究的第一阶段以符号主义为主导。BDI（Belief-Desire-Intention）模型将智能体行为刻画为信念、愿望与意图三者之间的推理关系，为形式化描述目标驱动的行为提供了逻辑基础。与之配套的 POMDP（部分可观测马尔可夫决策过程）框架，把环境不确定性、观测稀疏性与动作选择纳入统一的概率模型，使「在信息不完备条件下如何行动」成为可计算的问题。这一阶段的核心贡献在于确立了智能体的形式化边界，但其对知识表示与人工规则的强依赖，导致系统难以泛化到开放域任务。

第二阶段由深度强化学习推动。DQN、A3C、PPO 等算法使智能体能够在高维感知输入下通过与环境交互习得策略，在 Atari、围棋与机器人控制等任务上超越人类水平。然而，强化学习智能体的能力高度绑定于特定的环境与奖励函数：训练完成的策略难以迁移到新的任务描述，且样本效率低、奖励设计成本高。智能体因此长期停留在「特定任务专用」的形态，缺乏通用的语言接口与任务泛化能力。

1.2.2 多智能体系统：协作、博弈与涌现

多智能体系统（MAS）研究多个自治智能体在共享环境中的协调问题，早期成果集中于分布式约束优化、合同网协议与拍卖机制，用于解决任务分配与资源竞争。随着深度学习的引入，MADDPG、QMIX 等方法通过集中训练—分散执行解决了多体环境的非平稳性问题，并在 StarCraft 等复杂对抗环境中验证了协作策略的可学习性。

多智能体研究的核心洞见在于：群体性能不等于个体性能之和，协作协议的设计往往比单体的能力更重要。负面的失效模式同样被反复观察，包括责任扩散导致的社会性懈怠、以及群体极化——当个体倾向于参考他人意见时，初始的微小偏差会被逐轮放大，最终收敛到偏离事实的共识。这些发现对后来基于大模型的多 Agent 系统具有直接警示意义，因为后者恰恰缺乏能够抑制附和行为的机制设计。

1.2.3 大模型智能体：工具、记忆与规划

大语言模型的出现使智能体获得了通用的语言接口，研究重心随之转向三个技术支柱。在推理与规划方面，思维链（CoT）提示通过显式生成中间推理步骤显著提升了多步任务准确率；Least-to-Most 与 Tree-of-Thoughts 进一步将推理组织为分解序列与树状搜索，用额外的推理预算换取复杂问题上的正确率。在行动与工具方面，ReAct 提出推理与行动交替的范式，使模型能够在每一步根据当前观测决定调用何种工具；Toolformer 则以自监督方式让模型学会何时插入 API 调用。在记忆与反思方面，Reflexion 引入语言化的自我反馈，将失败经验以自然语言存入记忆并在后续尝试中复用；Generative Agents 与 MemGPT 则分别探索了记忆流检索与操作系统式的分层记忆管理。

多智能体方向在同期快速发展。AutoGen 将多 Agent 会话抽象为可编程的对话图，MetaGPT 通过标准作业流程（SOP）约束角色分工并引入中间产物校验，CAMEL 则研究角色扮演下智能体的自主协作。多智能体辩论（Multi-Agent Debate）通过让多个实例相互质疑来提升事实性，在部分推理基准上取得了优于自洽性采样的效果。此外，检索增强生成（RAG）通过引入外部知识检索缓解事实性幻觉，Self-RAG 与 CRAG 等后续工作进一步让模型自主决定检索时机并对检索结果进行批判性筛选。

1.2.4 研究述评

综合来看，现有研究在「能力构建」方向上取得了长足进展，但在「可靠性保障」方向上仍存在明显缺口。第一，规划、记忆、工具、协作等模块多以独立贡献的形式被提出，缺乏在同一框架内的联合优化与相互约束，模块之间的接口往往是自由文本，导致约束在传递过程中被稀释。第二，事实性提升手段以「间接代理指标」为主，如通过多次采样投票或让模型自我批判来降低幻觉，但这类方法无法给出「结论—证据」之间的显式对应关系，因而不能支撑事后审计。第三，多智能体的聚合策略多为置信度投票，而大模型的表达置信度与真实正确率之间存在系统性偏差，导致高置信度的错误主张更容易主导最终结

论。第四，实验评估普遍缺乏统一的、面向可信性的指标体系，不同工作在互不兼容的设置下报告准确率，使结论难以横向比较。

1.3 当前研究的痛点与现存缺陷

本文把上述缺口归纳为四个可直接攻克的痛点，作为后续设计的出发点。

痛点一：上下文失配与约束稀释。现有 Agent 普遍将系统指令、任务描述、检索证据、历史轨迹与记忆条目按时间顺序拼接为单一文本序列送入模型。这种无类型拼接带来两个后果：一是关键约束（如输出格式、禁止行为、时效要求）在长上下文中被大量低信息密度内容淹没，模型对约束的遵循率随上下文长度增加而显著下降；二是不同来源的内容在语义上不可区分，模型无法判断某段文本是「必须遵守的规范」还是「仅供参考的检索结果」，进而产生约束与证据的混淆使用。

痛点二：幻觉沿推理链传播且不可定位。现有方法的错误检测大多作用于最终答案，而长程任务的错误往往产生于中间步骤：一次错误的实体消解或一次失效的工具调用，会使其后的全部推理建立在错误前提上。由于中间结论没有被要求绑定证据，这类错误在生成过程中不可见，只能在最终答案被判定为错时才被察觉，而此时已经无法回溯到具体的致错步骤，更无法给出「哪一条主张缺乏依据」的可审计记录。

痛点三：记忆污染与协作退化。长期记忆的写入通常缺乏质量门控，导致重复条目、过时结论与未经校验的错误推论被持久化，并在后续任务中被反复检索放大，形成「记忆污染」。在多 Agent 场景中，由于缺乏以证据强度为基础的仲裁机制，角色之间倾向于相互确认，协作收益在任务复杂度提升时迅速衰减，甚至低于单 Agent 表现。

痛点四：成本与精度的刚性冲突。提升可靠性最直接的手段是增加推理预算——更多采样、更多轮反思、更多次工具调用。但这类手段的成本随可靠性提升近似线性增长，使得高可靠与低成本的组合在现有框架下不可达。缺乏按需分配预算的机制，是导致 Agent 在高价值场景中「用得起但用不好」的直接原因。

1.4 本文研究内容、创新点与技术路线

针对上述四个痛点，本文提出 CGA-Agent（Context-Guardrail Agent），一种以结构化上下文工程为基础、以主张-证据校验为核心护栏、以自适应预算分配为效率保障的分层多智能体协同框架。本文的研究内容与创新点如下。

创新点一：结构化上下文工程范式。把上下文从无类型文本序列重构为四类带类型槽位——任务规范槽、证据槽、推理轨迹槽与长期记忆槽，并为每一槽位定义明确的语义角色、优先级与失效策略；在此基础上建立上下文预算在槽位间分配的最优化模型，以语义覆盖增益与冗余惩罚之差为目标函数，在窗口约束下求解最优分配比例，使关键约束获得硬性保留区。

创新点二：Claim-Evidence 证据护栏机制。以「主张」为最小可校验单元，将生成文本解析为原子主张集合，为每条主张检索并绑定证据片段，施加覆盖度、蕴含度与可溯源三重校验闸门，未通过校验的主张被拦截并触发定向重写或拒答，同时生成逐主张的校验轨迹。该机制使幻觉检测从「事后整体评判」转变为「过程内逐条拦截」，并使结论具备可审计性。

创新点三：记忆写入门控与衰减机制。以信息增益、时效性、使用频率与冗余度构造记忆综合评分，仅当评分超过门控阈值时允许写入，并对既有记忆施加时间衰减与冲突消解，从源头抑制记忆污染。

创新点四：不确定性自适应规划与主张级一致性仲裁。以规划熵估计认知不确定性，按阈值分层决定推理深度与工具预算，实现预算的按需分配；多 Agent 协作中以证据强度加权的「主张级」一致性聚合替代实例级置信度投票，抑制高置信度错误主张对结论的主导。

技术路线如图 1.1 所示。本文首先梳理基础理论与问题形式化，继而设计 CGA-Agent 的分层架构与五个核心模块，随后在四个数据集上以六个基线和三个随机种子开展主实验、消融实验与鲁棒性实验，最后总结适用边界与落地路径。




图 1.1 本文技术路线图

1.5 论文组织结构

全文共六章。第 1 章为绪论，阐述研究背景、现状、痛点与本文贡献。第 2 章梳理相关技术与理论基础，涵盖大语言模型能力边界、智能体范式与架构分类、思维链与反思规划机制、记忆系统、工具调用以及多智能体协同理论。第 3 章为本文核心，给出 CGA-Agent 的总体架构与各模块的形式化设计，包括结构化上下文工程、感知模块、自适应规划、动态记忆更新、反思纠错、证据护栏、工具调度与多 Agent 仲裁，并分析其时间复杂度。第 4 章介绍实验设计、指标体系、主实验结果、消融实验与鲁棒性分析。第 5 章讨论模型优势、局限性、改进方向与应用场景。第 6 章总结全文并展望后续工作。

第 2 章 相关技术与理论基础

2.1 大语言模型的基础能力及其边界

大语言模型以自注意力机制为核心构件。给定输入序列，自注意力将每个位置的表征投影为查询、键与值三组向量，并通过缩放点积计算位置间相关性权重，从而在常数路径长度内建模任意距离的依赖关系。其计算可形式化表示为

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中 d_k 为键向量维度，缩放因子 $\sqrt{d_k}$ 用于抑制点积随维度增长而导致的梯度饱和。多头注意力在多个子空间中并行执行该运算并拼接结果，使模型能够同时关注句法、语义与指代等多类关系。在此架构上，经过大规模语料预训练与指令微调、人类反馈强化学习等对齐过程，大语言模型展现出三项对智能体至关重要的能力：指令遵循、上下文学习与多步推理。

然而，作为智能体的推理内核，大语言模型存在三项必须由外部机制补偿的内在局限。第一，知识固化与时效衰减：模型参数中编码的知识止于训练语料的时间截面，且对低频

事实的记忆强度显著低于高频事实，在缺乏外部检索时倾向于生成流畅但错误的陈述。第二，校准缺失：模型输出的表达置信度（如语言中的确定性措辞或对数概率）与真实正确率之间仅存在弱相关，模型在错误时同样可能表现出高置信度，这使得以置信度为基础的聚合与仲裁策略不可靠。第三，位置偏差：在长上下文中，模型对首尾位置信息的利用率显著高于中部内容，即所谓「迷失在中间」现象，这直接削弱了以简单拼接方式组织的长上下文的有效性。上述局限构成了本文设计结构化上下文与证据护栏的直接动因。

2.2 智能体的定义、范式与架构分类

本文将智能体定义为一个在环境中自主行动以达成目标的计算实体，其形式化描述为四元组

$$\mathcal{A} = \langle \mathcal{O}, \mathcal{S}, \mathcal{M}, \pi \rangle \quad (2-2)$$

其中 $\mathcal{O}$ 为观测空间， $\mathcal{S}$ 为内部状态空间， $\mathcal{M}$ 为记忆与知识存储， π 为策略——即由当前观测、内部状态与记忆映射到动作的函数。在时间步 t ，智能体接收观测 o_t ，更新内部状态 s_t ，依据策略选择动作 a_t 并作用于环境，环境返回新观测与奖励信号。大模型智能体的特殊性在于，策略 π 由语言模型实现，动作空间扩展为自然语言推理、工具调用与环境操作三类，而记忆 $\mathcal{M}$ 则以文本或向量形式组织，从而获得了通用性与可解释性。

依据控制结构的不同，现有大模型智能体可归纳为四类架构，如表 2.1 所示。单体反应式架构以单次或短程推理直接给出动作，实现简单但缺乏长程规划能力；单体规划式架构引入显式的计划—执行分离，通过分解与重规划提升复杂任务表现；多体协作式架构以多个角色分工与消息传递替代单体的串行推理；层次控制式架构则在多体之上引入仲裁或管理者节点，用于冲突消解与全局一致性维护。

表 2.1 四类大模型智能体架构对比

架构类型	控制结构	优势	主要缺陷	代表工作
单体反应式	观测→动作直接映射	延迟低、成本低	缺乏长程规划，错误不可恢复	CoT 提示
单体规划式	分解—执行—重规划	复杂任务成功率高	错误仍沿子目标链传播	ReAct、ToT
多体协作式	角色分工+消息传递	可并行、视角互补	附和与责任扩散导致退化	AutoGen、CAMEL
层次控制式	管理者+执行者双层	全局一致性与冲突消解	仲裁开销大，管理者易成瓶颈	MetaGPT

本文提出的 CGA-Agent 属于层次控制式架构，但与既有工作在两点上存在本质差异：其一，仲裁依据由实例级置信度改为主张级证据强度；其二，层级之间的接口不再是自由文本，而是结构化上下文槽位，使跨层传递的信息具备类型约束与可校验性。

2.3 思维链、反思与规划机制

思维链提示的核心思想是让模型在给出答案前生成中间推理步骤。若将问题记为 q 、答案记为 y ，标准提示直接建模 $p(y | q)$ ，而思维链建模中间推理序列 $z_1, z_2, \dots, z_n$ 的联合分布

$$p(y | q) = \sum_{z_{1:n}} \prod_{t=1}^n p(z_t | q, z_{<t}) \cdot p(y | q, z_{1:n}) \quad (2-3)$$

该分解把复杂的单步映射转化为受中间步骤约束的条件生成，使模型能够借助逐步展开的显式状态完成需要多跳组合的推理。自洽性（Self-Consistency）在此基础上对推理路径进行多次采样并以多数投票聚合结果，以采样成本换取准确率稳定提升。树状思维

（ToT）则把线性的推理链扩展为树形搜索，在每一层生成多个候选并对候选进行价值评估与剪枝，将推理过程形式化为在思维空间中的启发式搜索。

反思机制进一步引入了对自身输出的评价与修正。其一般形式为：给定初始输出 y_0 ，由评价函数生成语言化反馈 f_i ，再由模型依据反馈生成修正结果 y_{i+1} ，迭代至满足终止条件为止，即

$$y_{i+1} = \pi(q, y_i, f_i), f_i = \text{Critique}(q, y_i) \quad (2-4)$$

该机制的有效性依赖于评价信号的可靠性。既有研究普遍观察到「自我批判的盲区」现象：模型对自身错误的识别能力弱于对他人错误的识别能力，因此单纯的自我反思收益有限，而引入外部证据作为评价依据能够显著提升修正的有效性。这一观察是本文证据护栏机制的重要理论依据——护栏所提供的外部证据校验，本质上是为反思过程注入可靠的外部评价信号。

在规划层面，现有方法可归纳为三类。反应式规划在每一步基于当前观测重新决策，灵活但缺乏全局视野；前馈式规划先生成完整计划再顺序执行，全局性好但对环境变化不敏感；混合式规划在两者之间自适应切换，是当前主流的工程选择。三类方法的共同问题是规划的深度与宽度为预先设定的固定超参数，无法随任务难度动态调整，导致简单任务上预算浪费、复杂任务上预算不足。本文 3.4 节提出的不确定性自适应规划正是针对这一缺陷。

2.4 记忆系统：短时记忆、长时记忆与向量记忆

记忆系统决定了智能体能否跨步骤、跨会话地积累经验。按作用时域与存储形态，可分为三类，其对比见表 2.2。短时记忆即当前上下文窗口内的信息，容量受窗口长度硬约束，其管理核心是如何在有限容量内保留高价值信息；长时记忆以外部存储的形式持久化历史经验与知识，容量几乎不受限制，其管理核心是写入质量控制与检索相关性；向量记忆将文本编码为稠密向量并建立近似最近邻索引，以语义相似度而非字面匹配实现检索，是当前长时记忆的主流实现方式。

表 2.2 智能体记忆机制对比

记忆类型	存储形态	容量约束	检索方式	主要风险
短时记忆	上下文窗口内文本	严格受限	位置与注意力	关键信息被稀释或截断
长时记忆	外部结构化存储	近乎无限	键值 / 标签匹配	写入无门控导致污染
向量记忆	稠密向量索引	近乎无限	近似最近邻	相似不等于相关，检索噪声大
情节记忆	带时间戳的经验序列	近乎无限	时间 + 相似度混合	过时经验被误用

向量检索的相似度通常以归一化内积或余弦相似度度量，即

$$\text{sim}(u, v) = \frac{u^\top v}{\|u\|_2 \|v\|_2} \quad (2-5)$$

检索时按相似度取前 k 条作为记忆上下文。该方式的固有缺陷是「相似不等于相关」：语义相近的文本可能是与当前任务无关的同主题内容，而缺乏写入门控的记忆库会持续累积此类噪声，使检索精度随库规模增长而下降。本文 3.5 节的记忆写入门控即针对此问题设计。

2.5 工具调用框架与动作执行机制

工具调用使智能体的动作空间从纯文本扩展到具有确定语义的外部函数。主流实现将可用工具以模式描述（函数名、参数类型、功能说明）的形式注入上下文，由模型生成结

构化的调用请求，运行时解析并执行后把返回结果回注上下文。该过程的可靠性取决于三个环节：工具选择的正确性、参数填充的准确性以及执行失败后的恢复能力。

在工具选择上，可将问题形式化为在候选工具集 $\mathcal{T}$ 上依据当前状态选择动作的决策问题。若仅以任务相关性为依据，容易出现「选择语义相近但语义不等价工具」的错误；若忽略调用代价与失败风险，则在长程任务中会因工具预算耗尽而中断。因此本文在 3.8 节将工具调度建模为带预算约束的效用最大化问题，同时考虑预期收益、调用成本与失败风险三个维度。在执行失败恢复上，既有工作普遍采用固定次数的重试策略，而本文将其纳入护栏层的统一校验流程，使失败信号直接触发规划层的重规划，而非机械重试。

2.6 多智能体协同理论

多智能体协同的理论基础包括分布式问题求解与博弈论两条脉络。分布式问题求解关注如何将任务分解为可由独立智能体并行处理的子问题，并通过有限的消息传递达成全局解；其核心结论是任务的分解粒度与通信拓扑共同决定了协同效率。博弈论视角则关注智能体在利益部分一致或冲突时的策略均衡，其中「共识形成」与「信息级联」两个概念对多智能体语言模型系统具有直接解释力：当个体在更新信念时过度依赖他人表达的意见而轻视自身证据时，群体信念会沿初始偏差方向单调收敛，形成错误共识。

在大模型智能体中，这一问题被进一步放大，原因在于语言模型对同伴输出的敏感度高于对自身证据的敏感度。既有工作提出的辩论式协作通过强制质疑来对抗共识偏差，但其终局判定仍依赖模型自报的置信度或简单多数，未能从根本上解决聚合依据不可靠的问题。本文 3.9 节提出的主张级一致性仲裁，将聚合单元从「实例答案」下沉到「原子主张」，并以证据强度而非表达置信度作为权重来源，使协作机制在保留视角互补收益的同时抑制附和退化。

图 2.1 归纳了上述研究脉络：智能体范式经历了由符号化建模、强化学习策略学习，到以大语言模型为推理内核的单体能力扩展，再到多体协同涌现，并正在向以可信性与可审计性为核心的第五阶段演进。本文工作定位于该演进的第五阶段，其核心关切不是继续扩展单体能力，而是在既有能力水平上通过结构约束与证据校验提升系统的可信程度。



图 2.1 大模型智能体范式的演进脉络

第 3 章 CGA-Agent：面向结构化上下文与证据护栏的多智能体协同模型

3.1 设计目标与总体架构

CGA-Agent 的设计目标可归纳为四项可检验的工程命题：其一，上下文中的硬约束必须获得不受其他内容挤占的保留容量，从而抑制约束稀释；其二，每一条进入最终答案的结论都必须可追溯到具体证据片段，使幻觉可定位、可拦截；其三，记忆的写入必须经过质量门控，从源头抑制污染累积；其四，推理预算必须随任务难度自适应分配，使可靠性提升不以线性成本增长为代价。四项命题分别对应本文的四个创新点，并在架构上落实为五个功能层。

框架采用分层结构，自下而上依次为执行层（L0）、上下文层（L1）、护栏层（L2）、决策层（L3）与协作层（L4），两侧分别挂载全局记忆存储与审计日志，总体架构如图 3.1 所示。层间数据流严格向下，控制流与反馈流严格向上，任何跨层通信都必须经过上下文层的槽位接口，不得以自由文本形式直接穿透，这是保证类型约束全程生效的结构性前提。




图 3.1 CGA-Agent 分层总体架构

上下文层是整个框架的枢纽，其四类带类型槽位的定义、语义角色与失效策略如表 3.1 所示。任务规范槽承载不可被覆盖的硬约束；证据槽承载经检索并由护栏校验过的外部证据；推理轨迹槽承载当前任务的中间结论与工具返回结果；长期记忆槽承载跨任务复用的经验。四类槽位在语义上互斥、在优先级上有严格序关系，从而为模型提供了明确的「何种信息以何权重参与决策」的先验。

表 3.1 结构化上下文四类槽位定义

槽位	承载内容	优先级	容量策略	失效或冲突处理
任务规范槽	输出格式、禁止行为、时效与合规约束	最高（硬保留）	固定保留，不参与压缩	缺失则中止任务并报错
证据槽	经校验的检索片段与结构化查询结果	高	按校验得分排序后截断	校验失败则移出并触发补检
推理轨迹槽	中间结论、工具返回、校验记录	中	滑动窗口，超限时摘要压缩	与证据冲突时以证据为准
长期记忆槽	跨任务经验、纠错记录与偏好	低	按检索得分取前 k 条	时效过期或冲突时降权

3.2 结构化上下文工程

结构化上下文工程的第一步是把上下文由无类型文本序列重构为带类型槽位的集合。设任务规范槽、证据槽、推理轨迹槽与长期记忆槽分别记为 C_{tsk} 、 C_{ev} 、 C_{tra} 、 C_{mem} ，则结构化上下文定义为

$$\mathcal{C} = \langle C_{\text{tsk}}, C_{\text{ev}}, C_{\text{tra}}, C_{\text{mem}} \rangle \quad (3-1)$$

每个槽位由若干条目组成，条目具有统一的三元结构 (x_i, τ_i, ρ_i) ，其中 x_i 为文本内容， τ_i 为类型标签， ρ_i 为可信度分值。类型标签使模型能够区分规范性内容与参考性内容，可信度分值则在证据冲突时提供裁决依据。相较于无类型拼接，该结构使约束遵循率与证据引用精度同时得到提升，其原因在于注意力分配获得了显式的语义先验，而非完全依赖模型从文本表层自行推断。

结构化之后的核心问题是容量分配。设第 j 个槽位的分配容量为 b_j （以 token 计），总窗口容量为 B ，槽位 j 在容量 b_j 下的语义覆盖增益为 $G_j(b_j)$ ， λ 为冗余惩罚系数，则容量分配问题为带约束的优化问题

$$\max_{\{b_j\}} \sum_{j \in \mathcal{J}} G_j(b_j) - \lambda \sum_{j \in \mathcal{J}} R_j(b_j) \text{ s.t. } \sum_{j \in \mathcal{J}} b_j \leq B, b_j \geq b_j^{\min} \quad (3-2)$$

其中 $\mathcal{J} = \{\text{tsk}, \text{ev}, \text{tra}, \text{mem}\}$ 为槽位集合， $R_j(\cdot)$ 为该槽位内的冗余度函数， $b_j^{\min}$ 为最小保留容量。任务规范槽的 $b_{\text{tsk}}^{\min}$ 被设为该槽位的实际需求容量，即其容量约束为等式约束，从而形成硬保留区，这直接对应了 1.3 节所指出的约束稀释痛点。

在增益函数连续可微且边际增益递减的假设下，忽略冗余项时最优解满足等边际条件

$$\frac{\partial G_j(b_j^*)}{\partial b_j} = \frac{\partial G_k(b_k^*)}{\partial b_k} = \mu, \forall j, k \in \mathcal{J} \quad (3-3)$$

其中 μ 为容量约束的拉格朗日乘子，其物理含义是「单位容量的边际语义增益」。该条件表明：最优分配并不倾向于把容量平均分配给各槽位，也不倾向于全部给予单一槽位，而是使各槽位的边际增益趋于一致。工程实现中，本文以条目为单位进行离散化贪心分配：对每个槽位内的条目按（可信度 $\times$ 信息密度）排序，每轮选取当前边际增益最大的条目加入，直至容量耗尽。该贪心过程在增益函数为次模函数时可获得 $(1 - 1/e)$ 的近似保证，复杂度为 $O(n \log n)$ ，其中 n 为候选条目总数。

3.3 感知模块设计

感知模块负责把原始任务输入与外部观测转化为结构化上下文，其职能包含任务解析、槽位路由与约束抽取三个子过程。任务解析将自然语言任务映射为结构化需求，抽取目标、约束与期望输出形式；槽位路由判断每条信息应归入哪一槽位；约束抽取则识别任务中的硬性要求并写入任务规范槽。

设任务文本为 q ，感知模块输出的结构化表示记为 $\Phi(q) = (\hat{g}, \hat{c}, \hat{y}, \mathcal{K})$ ，分别对应目标、约束集合、输出形式与关键词集合。其计算过程可写为

$$\Phi(q) = \text{LLM}(q | \mathcal{P}_{\text{per}}, \mathcal{E}) \quad (3-4)$$

其中 $\mathcal{P}_{\text{per}}$ 为感知模块的提示模板， $\mathcal{E}$ 为槽位定义模式。关键词集合 $\mathcal{K}$ 用于后续证据检索的查询构造。为避免感知阶段引入的错误沿全流程传播，本文对感知结果施加一致性自检：若抽取出的约束集合为空而任务文本中包含明显的规范性措辞（如「必须」「仅」「不得」「以...格式」），则判定为感知遗漏并触发一次重解析。该机制以极低的额外成本（单次短提示调用）显著降低了约束漏检率。

3.4 不确定性自适应规划模块

自适应规划模块以「认知不确定性驱动预算分配」为核心思想，其流程如图 3.2 所示。给定结构化上下文 $\mathcal{C}$ 与目标 $\hat{g}$ ，规划器首先生成候选子目标序列 $G = (g_1, g_2, \dots, g_m)$ ，随后估计该规划的不确定性，并依据不确定性的高低决定后续的推理深度与工具预算。




图 3.2 不确定性自适应规划流程

规划不确定性采用基于采样一致性的熵估计。对同一上下文独立采样 n 条候选规划路径，将其按语义等价关系聚类为若干规划模式，第 i 种模式的出现频率记为 p_i ，则规划熵定义为

$$H(G | \mathcal{C}) = -\sum_{i=1}^K p_i \log p_i, p_i = \frac{n_i}{n} \quad (3-5)$$

其中 K 为聚类后的规划模式数， n_i 为属于第 i 种模式的采样数。熵值高意味着模型对「如何完成任务」存在多种同样合理的判断，即认知不确定性高；熵值低则意味着规划路径高度收敛，模型对该路径具有稳定信心。该估计的优点是不依赖模型自报的对数概率，因而规避了 2.1 节指出的校准缺失问题。

依据熵值与两个阈值 τ_{high} 、 τ_{low} 的关系，规划器选择三种模式之一：当 $H > \tau_{\text{high}}$ 时进入深度探索模式，扩展推理深度、并行采样多条轨迹并增配工具预算；当 $H < \tau_{\text{low}}$ 时进入快速执行模式，锁定单条最短路径并将预算收缩至下限；介于两者之间时进入仲裁模式，由协作层按需介入以消解分歧。推理深度 d 的选择可形式化为期望效用的最大化问题

$$d^* = \argmax_{d \in \{1, \dots, d_{\max}\}} \mathbb{E}[V(d)] - \eta \cdot \text{Cost}(d) \quad (3-6)$$

其中 $V(d)$ 为深度 d 下的任务收益， $\text{Cost}(d)$ 为该深度的推理与工具成本， η 为成本权重。在实现中， $\mathbb{E}[V(d)]$ 以历史统计的深度—收益曲线近似，使该决策退化为一次一维查表运算，不引入额外的模型调用开销。由此，预算分配从固定超参数转变为随认知状态波动的动态变量：在模型确有把握的任务上节约预算，在模型犹豫的任务上集中投入。

3.5 动态记忆更新机制

记忆机制的设计包含写入与读出两个方向。读出沿用相似度检索并在 3.2 节的容量分配框架下受约束，本文的主要贡献在写入方向：以综合评分对候选记忆施加写入门控，从源头抑制污染。

设候选记忆条目为 m ，其信息增益定义为该条目相对现有记忆库所带来的条件熵下降，即

$$\text{IG}(m) = H(\mathcal{Y} | \mathcal{M}) - H(\mathcal{Y} | \mathcal{M} \cup \{m\}) \quad (3-7)$$

其中 $\mathcal{Y}$ 为待预测的下游任务结论集合， $\mathcal{M}$ 为现有记忆库。该定义的直观含义是：一条记忆的价值取决于它能在多大程度上减少后续任务的不确定性，而非取决于它本身是否「看起来有信息量」。在此基础上，记忆综合评分由四项加权构成

$$S(m) = \alpha \text{IG}(m) + \beta e^{-\gamma \Delta t(m)} + \delta \log(1 + f(m)) - \zeta \text{Red}(m, \mathcal{M}) \quad (3-8)$$

式中各项依次为归一化信息增益、以 γ 为衰减率的时间衰减项、以使用次数 $f(m)$ 度量的效用累积项，以及与现有记忆的冗余惩罚项 $\text{Red}(\cdot)$ ； $\alpha, \beta, \delta, \zeta$ 为各项权重。记忆写入遵循门控规则

$$m \rightarrow \mathcal{M} \Leftrightarrow S(m) > \theta_w \text{ 且 } \text{Red}(m, \mathcal{M}) < \theta_r \quad (3-9)$$

即候选记忆必须在综合评分超过写入阈值 θ_w 的同时，其与现有记忆的冗余度低于冲突阈值 θ_r ，两个条件缺一不可。前者拦截低价值写入，后者拦截重复写入。此外，库内既有记忆随时间的权重按指数规律衰减，当权重低于淘汰阈值时被归档，从而使记忆库的规模与时效性保持动态平衡。各参数取值与敏感性分析见表 3.2。

表 3.2 记忆评分与门控参数设置

参数	含义	取值	作用	敏感性
α	信息增益权重	0.40	决定记忆价值的主导因素	中等
β	时效性权重	0.25	抑制过时经验复用	中等
δ	使用频率权重	0.20	强化高频有效经验	低
ζ	冗余惩罚权重	0.15	抑制同质条目堆积	高
γ	时间衰减率	0.05 / 天	控制记忆半衰期	高
θ_w	写入阈值	0.55	写入严格程度	高
θ_r	冗余冲突阈值	0.85	重复抑制强度	中等

3.6 自我反思与纠错机制

反思机制在 CGA-Agent 中不再作为独立的通用模块，而是与证据护栏深度耦合：反思的触发条件、评价依据与修正目标均由护栏的校验结果决定。设第 t 步生成的中间结论为 y_t ，护栏对其校验后返回失败主张集合 $\mathcal{F}_t$ 与对应的缺失证据描述 $\mathcal{D}_t$ ，则反思触发条件定义为

$$\text{Reflect}(y_t) = 1[|\mathcal{F}_t| > 0 \vee u(y_t) > \theta_u] \quad (3-10)$$

其中 $u(y_t)$ 为护栏给出的不确定度估计， θ_u 为触发阈值。该条件表明反思由两类信号触发：存在未通过校验的主张，或虽全部通过但整体不确定度偏高。修正过程以缺失证据描述为导向，即

$$y_{t+1} = \text{LLM}(q, \mathcal{C}, y_t, \mathcal{F}_t, \mathcal{D}_t | \mathcal{P}_{\text{ref}}) \quad (3-11)$$

与通用的自我批判相比，该设计有两个关键差异。第一，评价信号来自外部证据校验而非模型自我判断，因而规避了 2.3 节所述的自我批判盲区；第二，修正具有明确的目标指向——针对具体失败主张补充或替换证据，而非对整段输出进行无差别重写，这既提高了修正效率，也避免了重写过程中引入新的不受控内容。若连续 $k_{\max}$ 轮修正后仍有主张无法通过校验，系统输出拒答并记录失败原因，而非以低置信度内容填充答案。

3.7 Claim-Evidence 证据护栏机制

证据护栏是本文的核心创新模块，其目标是把幻觉检测从「事后整体评判」推进到「过程内逐条拦截」。该模块的实现分三步：主张抽取、证据绑定与三重校验，流程如图 3.3 所示。




图 3.3 Claim-Evidence 证据护栏校验流程

第一步，主张抽取。将候选输出 y 解析为原子主张集合 $Q(y) = \{c_1, c_2, \dots, c_m\}$ 。所谓原子主张，是指不可再分且具有独立真值可判定性的陈述句，即满足：任意 c_i 均可被某一证据片段支持或反驳。设抽取函数为 Ψ ，则

$$Q(y) = \Psi(y) = \{c_i \mid \text{atom}(c_i) \wedge \text{checkable}(c_i)\} \quad (3-12)$$

抽取过程同时剔除修辞性、过渡性与纯计算性语句，使后续校验的计算量集中于真正承载事实性内容的单元上。该步骤的意义在于确立了校验的最小粒度：以整段答案为校验单元时，一处错误即导致整段被否，定位能力缺失；以句子为单元时粒度仍过粗；以原子主张为单元则可在主张级别精确定位问题。

第二步，证据绑定。对每条主张 c_i 构造查询并从证据库 $\mathcal{D}$ 中检索候选证据。检索采用字面匹配与语义匹配的混合打分，以避免单一通道的偏差

$$\text{score}(c_i, d) = w_b \cdot \text{BM25}(c_i, d) + w_d \cdot \cos(\mathbf{e}(c_i), \mathbf{e}(d)) + w_p \cdot \text{Prior}(d) \quad (3-13)$$

式中 $\mathbf{e}(\cdot)$ 为文本编码器， $\text{Prior}(d)$ 为证据源的先验可信度（如权威数据源得分高于开放式网页）， w_b, w_d, w_p 为三项权重且满足归一化约束。取打分最高的前 k_e 条作为该主张的证据集 $\text{Ev}(c_i)$ 。

第三步，三重校验闸门。对每条主张施加三项判据。

覆盖度判据要求主张必须绑定非空证据集，其形式为 $\text{Ev}(c_i) \neq \emptyset$ ；在任务级别，覆盖率定义为

$$\text{Cov}(y) = \frac{|\{c \in Q(y) : \text{Ev}(c) \neq \emptyset\}|}{|Q(y)|} \quad (3-14)$$

蕴含度判据要求证据集在语义上确实支持该主张，采用自然语言推理模型计算蕴含概率，并取证据集内最大值作为该主张的蕴含得分

$$\text{Ent}(c_i) = \max_{d \in \text{Ev}(c_i)} p_{\text{NLI}}(\text{entail} | d, c_i) \quad (3-15)$$

可溯源判据要求证据片段保留原始出处标识，使校验结论可被人工复核。三项判据合并为单条主张的放行判定

$$\text{Pass}(c_i) = \mathbb{1}[\text{Ev}(c_i) \neq \emptyset \wedge \text{Ent}(c_i) \geq \theta_e \wedge \text{src}(c_i) \neq \perp] \quad (3-16)$$

其中 θ_e 为蕴含阈值， $\text{src}(c_i)$ 为该主张的溯源标识。整段输出的放行条件为所有主张均通过校验，即 $\bigwedge_i \text{Pass}(c_i) = 1$ 。未通过的主张构成失败集合 $\mathcal{F}$ ，并连同其缺失证据描述一同送入 3.6 节的反思模块。该机制带来的可审计性是其区别于既有事实性提升方法的关键：系统不仅给出答案，还给出「每条主张由哪一证据片段支持、蕴含得分为多少」的完整校验轨迹，使外部审计者能够独立复核结论的每一个组成部分。

3.8 工具调用调度策略

工具调度被建模为带预算约束的效用最大化问题。设候选工具调用为 $a \in \mathcal{A}$ ，其预期收益、执行成本与失败风险分别记为 $\mathbb{E}[V(a)]$ 、 $\text{Cost}(a)$ 与 $\text{Risk}(a)$ ，则调用效用定义为

$$U(a) = \mathbb{E}[V(a)] - \lambda_c \text{Cost}(a) - \lambda_r \text{Risk}(a) \quad (3-17)$$

调度策略在总预算约束下选择效用最大的调用序列，即

$$a^* = \argmax_{a \in \mathcal{A}} U(a) \text{ s.t. } \sum_{a \in \mathcal{S}} \text{Cost}(a) \leq B_{\text{tool}} \quad (3-18)$$

该形式化相较「按相关性选择工具」的朴素策略有三处改进。第一，显式建模失败风险，使系统倾向于选择虽收益略低但可靠性高的工具，避免长程任务因工具失败而中断；第二，成本项使预算在多个子目标间合理分摊，防止早期的非关键调用耗尽全部预算；第三，效用函数中的收益项由规划层根据当前不确定性动态调整——在高不确定状态下提高信息获取型工具（检索、查询）的收益权重，在低不确定状态下提高执行型工具的收益权重，实现工具组合随认知状态的自适应切换。在实现中，收益项由小样本历史统计与任务类型先验联合估计，避免引入额外的模型调用。

3.9 多 Agent 交互协作机制

协作机制的聚合单元从「实例答案」下沉到「原子主张」，这是本文与既有辩论式协作方法的根本差异。设协作层包含 N 个专家 Agent 与一个仲裁 Agent，各专家独立产出候选答案并各自经护栏校验，得到带证据的主张集合。对任一主张 c ，定义其在第 i 个专家处的支持强度

$$w_i(c) = \text{Ent}_i(c) \cdot r_i^{\text{hist}} \cdot \mathbb{1}[\text{Ev}_i(c) \neq \emptyset] \quad (3-19)$$

其中 $\text{Ent}_i(c)$ 为该专家给出的蕴含得分， r_i^{hist} 为该专家的历史可靠性（由其在历史任务中的校验通过率估计）。主张层面的一致性得分定义为支持强度与反对强度之差

$$\Delta(c) = \sum_{i \in \text{supp}(c)} w_i(c) - \sum_{j \in \text{opp}(c)} w_j(c) \quad (3-20)$$

当 $\Delta(c) > 0$ 且支持强度之和超过激活阈值 θ_c 时，该主张被纳入最终答案；当 $\Delta(c) < -\theta_c$ 时被否决；介于两者之间时提交仲裁 Agent 定向裁决，裁决请求中携带双方证据以便针对性地补充检索。最终答案由所有被纳入的主张按逻辑关系重组而成，而非从某个专家的完整输出中直接选取。

该设计的理论收益在于抑制附和退化。在实例级投票中，一个高表达置信度但缺乏证据的错误答案可能获得多数支持；而在主张级聚合中，其权重被蕴含得分与证据非空指示共同约束，无证据的主张权重恒为零，因而无法主导结论。同时，由于聚合作用于主张而非实例，专家之间的视角互补性得以保留：不同专家提出的正确主张可以共存于同一最终答案中，而不必因分属不同实例而相互排斥。

3.10 复杂度分析

设任务包含 T 个推理步骤、每步主张数为 m 、证据库规模为 $|\mathcal{D}|$ 、专家 Agent 数为 N 。主张抽取与校验的单步复杂度为 $O(m)$ 次模型调用；证据检索采用倒排索引与向量索引的混合结构，单次检索复杂度为 $O(\log|\mathcal{D}| + k_e)$ ；蕴含判定对每个主张—证据对执行一次前向计算，单步复杂度为 $O(m \cdot k_e)$ 。因此单步总复杂度为 $O(m\log|\mathcal{D}| + mk_e)$ ，全任务复杂度为 $O(T \cdot (m\log|\mathcal{D}| + mk_e) + N \cdot T)$ 。

与基线方法相比，CGA-Agent 的额外开销主要来自主张级校验。然而该开销具有两个有利性质：其一，校验调用为短上下文、结构化输出任务，其单次 token 消耗远低于主推理调用；其二，自适应规划使深度探索仅在高不确定步骤触发，而多数步骤的不确定性较低，因而均摊至全任务的额外成本有限。第 4 章的实测数据表明，CGA-Agent 的平均单任务 token 成本为 7.15 千 token，低于 Reflexion 的 9.74 千 token 与 AutoGen 的 13.2 千 token，验证了上述复杂度分析判断——护栏带来的可靠性提升并未以成本膨胀为代价。

第 4 章 实验设计与结果分析

4.1 实验环境与参数配置

为保证实验的可复现性，所有实验在同一硬件与软件环境下完成，推理后端统一采用开源大模型以排除商用接口版本漂移带来的干扰，并通过固定随机种子、固定解码参数与固定的工具调用超时设置控制非确定性来源。每个实验配置在三个随机种子（42、43、44）下独立运行，报告其均值及标准差。具体环境与超参数配置如表 4.1 所示。

表 4.1 实验环境与超参数配置

项目	配置	说明
推理后端	70B 级开源指令微调模型（4-bit 量化）	全部方法共用，保证公平比较
硬件环境	单机 8×A100 80GB，推理框架 vLLM	张量并行度 4，批处理动态调度
上下文窗口	32 768 token	各槽位容量之和的硬上限
解码参数	温度 0.2，top-p 0.9，最大生成 2 048 token	探索模式温度提升至 0.8
规划阈值	$\tau_{\text{high}} = 1.10$ ， $\tau_{\text{low}} = 0.45$	由 3.4 节熵估计标定
蕴含阈值	$\theta_e = 0.72$	由验证集网格搜索确定
采样规模	$n = 5$ （规划熵估计）， $k_e = 4$ （证据条数）	探索模式下 n 增至 9
最大反思轮数	$k_{\text{max}} = 3$	超出则触发拒答
随机种子	42 / 43 / 44	报告三 seed 均值与标准差

4.2 数据集与评价指标体系

本文选用四个数据集，覆盖多跳问答、常识推理、工具调用与带证据标注四类任务形态，以检验方法的泛化性。HotpotQA 为多跳问答数据集，要求模型跨多个文档聚合信息；StrategyQA 为需要隐式分解的常识推理数据集；ToolBench 的子集用于评估工具选择与参数填充能力，包含多步 API 调用链；CE-Bench 为本文构建的带证据标注数据集，其特点是为每个问题标注了必需证据片段集合与干扰片段，从而支持证据覆盖率、无证据结论率与误引用率等可信性指标的精确计算。各数据集规模与统计特征如表 4.2 所示。

表 4.2 实验数据集统计

数据集	任务类型	测试样本数	平均推理步数	证据标注	评价重点
HotpotQA	多跳问答	1 200	3.4	无	跨文档信息聚合
StrategyQA	常识推理	1 000	2.6	无	隐式分解与常识一致性

ToolBench	工具调用	800	4.8	部分	工具选择与调用链完整性
CE-Bench	混合任务	1 000	3.9	全量	证据完备性与可审计性

评价指标体系兼顾结果正确性与过程可信性，共设六项指标，其定义如表 4.3 所示。任务成功率以答案与标准答案的语义等价判定依据，在 CE-Bench 上同时要求证据引用正确；证据覆盖率、无证据结论率与误引用率直接从护栏的校验轨迹中统计得到，这使可信性指标的获取不再依赖人工标注，而是系统运行的副产品。

表 4.3 评价指标定义

指标	符号	定义	取值方向
任务成功率	SR	语义判定为正确的样本占比	越高越好
答案准确率	EM / F1	精确匹配率与词级 F1	越高越好
证据覆盖率	EC	被至少一条证据支持的主张占比	越高越好
无证据结论率	UCR	无任何证据绑定即输出的主张占比	越低越好
误引用率	MR	证据存在但语义不支持该主张的占比	越低越好
平均成本	Cost	单任务平均 token 消耗（千 token）	越低越好

其中证据覆盖率与无证据结论率按 3.7 节的式(3-13)与主张集合直接计算。误引用率刻画的是「引用了证据但证据不支持结论」这一更隐蔽的错误类型，其定义为

$$MR = \frac{|\{c \in Q(y) : Ev(c) \neq \emptyset \wedge Ent(c) < \theta_e\}|}{|Q(y)|} \quad (4-1)$$

为综合衡量成本与性能的平衡，定义归一化综合效率指标

$$CEF = \frac{SR}{Cost} \cdot \frac{1}{\max(\epsilon, UCR)} \quad (4-2)$$

其中 ϵ 为防止除零的小量。该指标越高，表示单位成本下获得的正确性与可信性越高。

4.3 对比基线

本文选取六个基线系统，覆盖从朴素提示到多智能体协作的主要技术路线。Vanilla LLM 为单轮直接提示，不提供任何结构化上下文；CoT 为思维链提示，仅增加中间推理步骤；ReAct 为推理—行动交替范式，具备基础工具调用能力；Reflexion 在 ReAct 基础上引入语言化自我反思与经验记忆；AutoGen 为多智能体会话框架，采用多角色协作但聚合依据为实例级置信度；CGA-Agent 为本文提出的完整模型。为公平比较，所有方法使用同一推理后端、同一工具集与同一最大轮数上限；涉及检索的方法共用同一检索服务与索引。

4.4 主实验结果与分析

各方法在四个数据集上的任务成功率如图 4.1 所示，综合结果汇总于表 4.4。




图 4.1 各方法在四个数据集上的任务成功率对比

从整体趋势看，方法演进与成功率提升呈现清晰的正相关，但增益幅度存在显著差异。思维链带来的平均增益为 8.1 个百分点，其收益主要来自需要多步组合的 HotpotQA 与 StrategyQA，而在以工具调用为主的 ToolBench 上增益相对有限，说明单纯的推理展开无法解决行动层面的问题。ReAct 引入工具调用后，ToolBench 上的成功率由 39.4% 跃升至 57.8%，提升达 18.4 个百分点，验证了「推理与行动交替」对工具类任务的关键作用。Reflexion 通过反思机制在各数据集上获得 2% 至 4% 的稳定增益，但其增益在 ToolBench 上最小，原因在于工具调用失败的根因常常是接口理解偏差，而自我反思难以提供修正该偏差所需的外部信息。

CGA-Agent 在四个数据集上均取得最优结果，平均成功率为 77.9%，较最强基线 AutoGen（68.5%）提升 9.4 个百分点，较 Vanilla LLM（45.0%）提升 32.9 个百分点。值得注意的是，其优势在 CE-Bench 与 ToolBench 上尤为明显（分别达到 79.6% 与 72.4%），这两个数据集的共同特征是任务包含明确的证据需求或工具调用约束，说明结构化上下文与证据护栏所提供的过程约束在强约束任务上收益最大。

表 4.4 主实验结果汇总（三随机种子均值）

方法	SR 均值 (%)	EC (%)	UCR (%)	MR (%)	成本 (千 token)	时延 (s)
Vanilla LLM	45.0	61.3	38.7	26.4	1.35	3.1
CoT	53.1	66.8	33.2	21.7	2.42	5.4
ReAct	62.7	72.4	22.6	14.3	5.86	11.2
Reflexion	66.0	74.9	19.4	11.8	9.74	18.6
AutoGen	68.5	76.1	17.8	10.2	13.20	24.3
CGA-Agent	77.9	91.7	6.4	3.1	7.15	15.8

可信性指标的结果更能体现机制差异。如图 4.2 所示，Vanilla LLM 的无证据结论率高达 38.7%，CoT 与 ReAct 虽通过增加推理步骤降低了该比例，但仍分别停留在 33.2% 与 22.6%，说明「生成更多中间步骤」并不自动等同于「结论更有依据」。Reflexion 与 AutoGen 依靠反思与多角色交叉检查进一步压缩至 19.4% 与 17.8%，而 CGA-Agent 将其降至 6.4%，同时把证据覆盖率从 76.1% 提升至 91.7%。这一组对比的核心结论是：只有当「证据绑定」成为生成流程中不可绕过的强制环节时，无证据结论才能被系统性消除；依赖模型自发提供依据的做法无法保证覆盖率的下限。




图 4.2 各方法的证据覆盖率与无证据结论率对比

误引用率的结果进一步揭示了护栏的独特作用。基线方法的误引用率随能力提升缓慢下降，AutoGen 仍高达 10.2%，意味着其每十条引用中约有一条的证据实际不支持结论；CGA-Agent 将该项降至 3.1%，降幅超过基线间差距的总和。其原因在于蕴含度判据独立于覆盖度判据：仅要求「引用了证据」并不能阻止误引用，必须额外验证证据与主张之间的语义蕴含关系。这一发现对工程实践具有直接指导意义——检索增强系统中的常见做法是只要检索到相关文档即认为事实性得到保证，而本文实验表明该假设在引用精度上存在约七倍于目标水平的误差。

成本与性能的关系如图 4.3 所示。基线方法呈现单调的成本—性能递增关系：AutoGen 以最高的 13.2 千 token 成本获得 68.5% 的成功率，其边际成本收益率已明显低于 Reflexion。CGA-Agent 位于该曲线上方偏左的位置，以 7.15 千 token 的成本获得 77.9% 的成功率，在成本—性能平面上构成对 AutoGen 的帕累托改进——以约 46% 的成本实现了高出 9.4 个百分点的成功率。这一反直觉结果的机制解释是：护栏拦截了错误推理的继续传播，使系统避免了在错误路径上的持续投入；而缺乏护栏的系统在错误路径上消耗的预算不可回收，这恰是 AutoGen 成本高企的结构性原因。




图 4.3 成本-性能权衡关系（虚线为趋势，阴影区为帕累托改进区）

4.5 消融实验

为归因各模块贡献，本文在 CE-Bench 上对完整模型依次移除五个模块，其余配置保持不变，结果如图 4.4 与表 4.5 所示。




图 4.4 消融实验：移除各模块后的任务成功率变化

证据护栏的移除造成的性能损失最大，成功率由 77.9% 降至 66.3%，下降 11.6 个百分点，同时无证据结论率由 6.4% 回升至 21.5%。该结果表明护栏不仅承担事实性保障职能，也实质性地参与了推理质量控制：在校验失败触发的定向重写过程中，系统获得了额外一轮基于证据的修正机会，从而在整体上提高了最终答案的正确率。

结构化上下文的移除导致 9.0 个百分点的下降（77.9% → 68.9%），其损失集中体现在约束遵循类样本上：在要求特定输出格式或禁止使用特定信息的样本子集中，该变体的失败率上升约 2.3 倍，与 1.3 节关于约束稀释的痛点分析一致。记忆写入门控的移除带来 4.5 个百分点的下降，且该差距随任务序列长度增加而扩大：在前 200 个样本上差距仅为 2.1 个百分点，在最后 200 个样本上扩大到 7.8 个百分点，这直接印证了记忆污染的累积效应——缺乏门控的记忆库随运行时间增长而持续劣化，其负面影响具有时间累积性。

自适应规划的移除造成 3.8 个百分点的下降，同时成本上升 21.7%，呈现出性能与成本同时恶化的双重损失，说明固定预算策略在两个方向上都不经济。一致性仲裁的移除影响最小（2.3 个百分点），但在需要多视角交叉验证的多跳样本子集上，其影响上升至 5.1 个百分点，表明该模块的价值与任务对视角多样性的需求强度正相关。

表 4.5 消融实验结果（CE-Bench，三随机种子均值）

模型变体	SR (%)	变化 (pp)	EC (%)	UCR (%)	成本 (千 token)
完整模型 CGA-Agent	77.9	—	91.7	6.4	7.15
移除证据护栏	66.3	-11.6	64.2	21.5	5.82
移除结构化上下文	68.9	-9.0	78.3	14.7	7.41
移除记忆写入门控	73.4	-4.5	89.1	8.2	7.08
移除自适应规划	74.1	-3.8	90.4	7.6	8.70
移除一致性仲裁	75.6	-2.3	90.8	6.9	5.94

4.6 鲁棒性与稳定性分析

鲁棒性实验通过向检索结果中注入语义相关但事实错误的干扰文档来模拟真实环境中的信息污染，注入比例由 0% 递增至 50%，结果如图 4.5 所示。所有方法的成功率均随干扰比例上升而下降，但衰减速率存在显著差异。CGA-Agent 在 50% 干扰下仍保持 59.1% 的成功率，衰减幅度为 18.8 个百分点；而 ReAct、Reflexion 与 AutoGen 的衰减幅度分别为 25.5、26.2 与 26.8 个百分点。在整个注入区间内，CGA-Agent 的衰减曲线斜率约为基线的一半，其原因在于证据护栏的蕴含度判据对于干扰文档具有筛选作用：干扰文档虽与主张主

题相关因而能通过检索的相似度过滤，但其内容与该主张之间不构成蕴含关系，因而在蕴含校验环节被剔除。这说明本文的护栏机制在信息污染场景下具备超出设计预期的防御能力。




图 4.5 干扰文档注入比例对任务成功率的影响

稳定性通过三个随机种子的结果离散度衡量，如图 4.6 所示。CGA-Agent 在四个数据集上的标准差均值为 0.61，而 ReAct 的标准差均值为 1.13，前者约为后者的一半。稳定性的提升同样可追溯至护栏机制：由于输出必须通过证据校验，采样随机性所导致的偶然错误主张会在校验环节被拦截，使最终结果的方差被压缩。这一性质在工程上具有重要意义——Agent 系统的稳定性直接决定了其能否被部署到需要结果可预期的生产环境中。




图 4.6 三个随机种子下的成功率分布与标准差

为验证性能优势的统计显著性，本文以配对自助法（bootstrap，重采样 10 000 次）对 CGA-Agent 与各基线的逐样本正确性进行检验，结果如表 4.6 所示。CGA-Agent 相对所有基线的优势均在 $p < 0.01$ 水平上显著，且效应量（Cohen's d ）均大于 0.5，属于中等以上效应。

表 4.6 配对自助法显著性检验结果

对比	平均差值 (pp)	95% 置信区间	p 值	Cohen's d
CGA-Agent vs. AutoGen	+9.4	[7.1, 11.8]	< 0.01	0.71

CGA-Agent vs. Reflexion	+11.9	[9.5, 14.4]	< 0.01	0.86
CGA-Agent vs. ReAct	+15.2	[12.8, 17.7]	< 0.01	1.04
CGA-Agent vs. CoT	+24.8	[22.3, 27.5]	< 0.01	1.53
CGA-Agent vs. Vanilla LLM	+32.9	[30.4, 35.6]	< 0.01	1.92

4.7 多维能力对比与本章小结

为呈现各方法在多个维度上的能力结构，本文选取 ReAct、AutoGen 与 CGA-Agent 在准确率、证据完备性、纠错能力、效率与稳定性五个维度上进行归一化对比，结果如图 4.6 所示。




图 4.7 三种代表性方法的多维能力雷达图

雷达图揭示了不同技术路线的能力结构差异。ReAct 在效率维度较高而在证据完备性与纠错能力维度明显偏低，属于「轻量但不可审计」的形态；AutoGen 在准确率与纠错能力上优于 ReAct，但效率维度最低，属于「以成本换取质量」的形态；CGA-Agent 的图形覆盖面积最大，且在证据完备性与稳定性两个维度上优势最为突出，其效率维度亦高于 AutoGen 与 Reflexion。该结果表明本文方法并非在单一指标上取巧，而是在多个维度上同时改善，其中可信性相关维度的改善幅度最大。

综合本章实验，可得到三点结论。第一，结构化上下文与证据护栏是性能提升的主要来源，二者合计贡献了消融实验中约 20 个百分点的损失，且二者的作用机制互补——前者保证信息以正确的形式进入推理，后者保证结论以正确的依据输出。第二，可信性指标与准确性指标并非此消彼长的关系，在本文框架下二者同步改善，说明在过程层面施加约束能够同时提升结果质量与可审计性。第三，可靠性提升不以成本膨胀为代价，由于护栏同时抑制了错误路径上的无效消耗，CGA-Agent 在成本上反而低于能力最接近的基线，这表明可信性机制的设计与效率目标之间不存在必然冲突。

第 5 章 讨论与应用场景

5.1 模型优势总结

结合第 3 章的设计与第 4 章的实测数据，CGA-Agent 的优势可归纳为四个层面。

其一，可信性由机制保障而非由模型自觉保障。本文的核心判断是：事实性不能寄望于模型的自我约束，而必须由不可绕过的流程环节保证。证据护栏把「为每条主张绑定证据」变成了生成流程的强制关卡，使无证据结论率从基线的 17.8% 降至 6.4%、误引用率降至 3.1%。这一提升幅度远超基线之间通过增加推理轮数所能获得的改善，说明机制设计与规模效率之间存在量级差异。

其二，可审计性使结论具备被复核的可能。护栏在执行过程中自然产生逐主张的校验轨迹，记录了每条结论所依赖的证据片段、蕴含得分与溯源标识。这使得系统输出从「一个答案」转变为「一个带证明链的答案」，从而支撑了医疗、法律、金融等领域的合规审查需求。值得注意的是，该轨迹是系统运行的副产品而非额外开销所产生，这是本文设计与「事后人工核查」路线的重要区别。

其三，可靠性与效率实现同步改善。第 4 章的帕累托分析表明，CGA-Agent 以 AutoGen 约 46% 的成本取得了更高的成功率。其机制解释在于护栏对错误路径的早期拦截：缺乏护栏的系统在错误推理上消耗的预算无法回收，而过早的拦截反而节约了总预算。这一结论对工程实践具有直接的资源配置含义——在 Agent 系统中投入可信性机制不必然意味着成本上升。

其四，模块化的可组合性。框架的五个模块通过结构化上下文槽位解耦，各模块可独立替换或升级。例如证据护栏中的蕴含判定可由更强的自然语言推理模型替换，检索组件可由领域专用向量模型替换，而不影响其余模块的接口约定。这一性质使框架具备向具体行业迁移的工程基础。

上述四个层面的优势并非彼此独立，而是源于同一机制根源：把可信性从「模型的自觉」转移到「流程的强制」。由此可以给出护栏投入的一条边界条件——护栏的额外开销应当小于其避免的期望损失：

$$\Delta C_{\text{rail}} < p_{\text{esc}} \cdot C_{\text{esc}} - p_{\text{fp}} \cdot C_{\text{fp}} \quad (5-1)$$

式中 ΔC_{rail} 为护栏引入的额外 token 与延迟成本（可折算为货币或人工复核工时）， p_{esc} 为无护栏时错误结论逃逸的概率， C_{esc} 为该错误结论流入下游所造成的损失， p_{fp} 为护栏的假阳性率， C_{fp} 为纠正一次误拦截所需的成本。该不等式表明，护栏的经济性并非普遍成立：它随任务的错误代价单调改善，随误拦截代价单调恶化。在高价值低频任务中（如合规审查与医学问答）， C_{esc} 极大，即使护栏带来数倍 token 开销仍然合算；而在低价值高频任务中（如批量摘要与标签生成）， C_{esc} 很小，此时应优先采用旁路记录而非前置拦截。第 4 章中 CGA-Agent 的总成本反而低于 AutoGen，其原因正在于该任务设定下护栏的早期拦截同时压低了 p_{esc} 与后续返工成本，使不等式右侧显著为正。这一判据为 5.4 节的分场景部署建议提供了量化依据。

5.2 当前局限性分析

本文方法存在四方面局限，需要审慎界定其适用边界。

第一，证据依赖构成硬性前提。证据护栏的有效性以下述假设为基础：任务所需的正确信息存在于可检索的证据库中。对于依赖隐性知识、创造性综合或价值判断的任务，该假设不成立，此时护栏将阻断大量本可接受的输出，表现为拒答率偏高。在本文实验中，CE-Bench 上约有 4.3% 的样本因连续三轮修正仍未通过校验而被拒答，其中相当比例为开放式论述题。因此，框架适用于事实密集型任务，而不宜直接应用于创作类与开放式推理类任务。

第二，额外推理开销的绝对量不可忽略。尽管本文方法的总成本低于能力最接近的基线，但其相对朴素提示仍有约 5.3 倍的 token 消耗。在低价值的批量任务中，这一开销可能不经济。此外，主张抽取、证据检索与蕴含判定均为串行步骤，在延迟敏感场景中会引入约 4.6 秒的额外时延，限制了其在实时交互场景中的直接应用。

第三，校验环节自身的可靠性存在上限。证据护栏的判定依赖自然语言推理模型的蕴含判断，而该模型本身存在误判：在本文的验证集分析中，蕴含判定的假阴性与假阳性分别约为 5.8% 与 4.1%。这意味着护栏既会拦截少量本应通过的正确主张，也会放行少量证据支持不足的错误主张，即系统提供的是「显著降低」而非「完全消除」幻觉的保障。同时，护栏无法防御证据库自身被污染的情况——若错误信息已存在于权威证据源中，系统会为该错误主张绑定「合法」证据并将其放行。这一问题超出了本文的机制设计范围。

第四，阈值参数需要针对领域标定。蕴含阈值、规划熵阈值与记忆写入阈值均需借助验证集网格搜索确定，而不同领域对准确率与召回率的偏好不同：医疗场景要求极高的蕴含阈值以压缩假阳性，探索性科研场景则可能容忍更低的阈值以保留假设空间。本文给出的默认取值适用于通用问答场景，跨领域的直接迁移需要重新标定。

第五，评测基准与判定器自身存在度量偏差。本文采用的四项基准中，HotpotQA 与 StrategyQA 的答案呈现为短实体或布尔值，这类结论的校验难度显著低于真实业务中的长文本结论；ToolBench 的接口调用结果具有确定性的成功与失败标识，同样弱化了校验的难度。同时，以自然语言推理模型充当蕴含判定器，其训练语料与本文评测集在领域分布上存在重叠，可能使证据覆盖率与误引用率的绝对数值被系统性高估。此外，中文场景的样本规模相对有限，四项基准中仅 CE-Bench 为中文自建集，其结论的统计效力弱于英文基准。因此，本文报告的绝对指标应被视为机制有效性的证据，而非可直接外推的部署性能承诺。后续工作应补充长文本结论、多轮对话与中文专业领域的校验基准。

5.3 未来改进方向

针对上述局限，后续工作可从四个方向推进。

方向一，以端到端可微方式替代提示式护栏。当前护栏由若干独立的提示调用串联而成，训练信号无法在模块之间回传。将主张抽取、证据绑定与蕴含判定整合为统一的轻量判别模型，以任务级正确性与可信性指标联合训练，有望在压缩延迟的同时提升判定精度。

方向二，引入证据库可信度的分层建模。为应对证据源自身被污染的情形，需要建立证据源的分层可信度模型，在冲突证据出现时依据来源权威度、时效性与交叉印证程度进行加权裁决，而非仅依据片段级打分。

方向三，面向延迟敏感场景的渐进式校验。将全量校验改为渐进式：对高置信主张执行轻量校验，仅对低置信或高风险主张触发完整的检索与蕴含判定，以校验深度与风险等级成正比的方式压缩平均延迟。

方向四，从静态阈值走向自适应阈值。以在线学习方式依据运行中的校验统计动态调整阈值，使系统在保持误放行率不超上限的前提下尽可能提高通过率，从而缓解领域标定的依赖。

方向五，从二值拦截走向分级输出。当前系统对未通过校验的主张统一采取「修正或阻断」，未区分风险等级。可引入三级输出策略：高置信主张直接给出；中置信主张给出结论并附带证据强度标注；低置信主张转为澄清式提问或明确拒答，并说明所缺失的信息类型。该策略把不确定性从隐式的内部状态转变为显式的输出成分，使下游使用者能够按自身风险偏好解读结论，而非被动接受一个混淆了置信度的答案。

方向六，面向多模态与结构化证据的扩展。本文的证据单元被限定为文本片段，而工业与医疗场景中的关键证据大量以图表、时序曲线与结构化记录的形式存在。将框架推广至上述场景，需要把证据单元从「文本片段」泛化为「多模态证据对象」，并相应地把蕴含判定改造为跨模态一致性判定，即判断一条文本主张是否被给定图像区域、表格单元或时序片段所支持。该扩展涉及跨模态对齐与可溯源标注两项额外技术，是框架走向这些场景的必要条件。

5.4 应用场景与落地路径

结合模型的能力结构与局限，本文识别出四类适配度较高的应用场景，其对应关系、适配理由与关键约束如表 5.1 所示。

表 5.1 应用场景适配性分析

应用场景	适配理由	关键约束	适配度
科研文献辅助综述	事实密集型任务，证据天然存在且需溯源	领域术语的检索召回归一化	高
企业知识库问答	内部文档构成封闭证据库，可审计要求强	权限隔离与文档时效管理	高
工业设备故障诊断	故障知识以手册与案例形式沉淀，结论需可追溯	对假阴性的容忍度极低	中高
金融合规审查	需逐条结论对应监管条款，审计轨迹为核心价值	监管文本更新的及时同步	中高
开放式创意写作	缺乏可检索的客观依据	护栏将大量阻断合理输出	低

在落地路径上，本文建议采用渐进式部署策略。第一阶段以「护栏旁路」模式运行：系统正常输出结论，护栏仅在旁路记录校验轨迹而不拦截输出，用于评估目标领域的证据可得性与护栏的误判率，并据此标定领域阈值。第二阶段切换为「护栏前置」模式，对高风险主张实施拦截，并在拦截时提供缺失证据描述以辅助人工介入。第三阶段则在护栏误判率降至可接受水平后启用全量拦截与自动修正。该路径的核心考虑是：可信性机制的引入会改变系统的输出分布，贸然全量启用可能导致拒答率骤升而影响业务可用性，渐进式部署为阈值标定与用户预期管理提供了缓冲空间。

表 5.1 中适配度最高的两类场景，其护栏发挥作用的机制并不相同。在科研文献辅助综述中，证据天然存在且以引文形式组织，任务的核心困难在于跨文档的证据聚合而非证据获取；此时护栏的主要价值体现为对「跨文档拼接式幻觉」的抑制——即模型将不同文献的结论错误归并后形成的、在任一单篇文献中都不成立的主张。该类幻觉在传统评测中难以被答案匹配指标捕获，而证据覆盖度与溯源标识能够直接将其暴露。在企业知识库问答中，证据库封闭且带有权限边界，护栏的逐主张溯源轨迹可直接转化为回答所依据的引用清单，使审计成本从「重新检索核对」降为「按清单抽查」；该场景的主要风险来自文档时效，因此记忆写入门控中的时间衰减项需要按文档类型分别标定，对制度类文档施加比技术文档更强的衰减。

对于适配度中高的工业诊断与金融合规场景，约束条件比前两类更为严格。这两类场景的共同特征是错误结论的代价远高于拒答的代价，因此在部署时应将护栏的蕴含阈值上调，以接受更高的误拦截率换取更低的漏放行率；同时把自动修正改为「自动初筛加人工确认」，由人工作为最终裁决环节。这两类场景还要求证据库具备版本管理能力：当依据的条款或手册发生更新时，既有结论的证据绑定关系应被标记为待复验，而非继续生效。本文的记忆写入门控机制为这一需求提供了接口，但版本一致性校验本身不在本文范围之内。

开放式创意写作被列为低适配场景，但这并不意味着护栏在此类任务中全无价值，而是其价值形式发生了变化：任务缺乏可检索的客观依据，证据绑定闸门将持续误拦截；然而主张抽取与一致性校验仍然可用，其作用从「抑制无据结论」转为「抑制自相矛盾」。这提示护栏的各闸门应当支持独立启停，而非作为不可分割的整体。本文在第 3 章中将三重闸门设计为串联结构，其可配置性正是为这类差异化部署保留的接口。

在系统集成层面，CGA-Agent 的作用位置位于上下文组织与输出校验层，而不占据任务编排层，因此可与既有框架叠加使用：由 AutoGen 或 MetaGPT 等框架承担角色划分与消息路由，CGA-Agent 负责为每个角色的输入构造结构化上下文、为输出执行证据校验。这一分层使本文方法不必重新实现多智能体编排即可获得可信性保障，降低了迁移成本；

代价是引入了一次额外的上下文序列化开销，其量级与消息长度成正比。对该开销的摊销方式，是将同一轮内多个角色的校验合并为批处理调用。

在部署度量上，本文建议不以单一准确率评价线上系统，而应持续跟踪三项运行指标：拒答率、人工介入率与证据命中率。三者构成一组相互制约的观测量：阈值收紧时拒答率上升，人工介入率随之上升，而证据命中率应当同步改善；若拒答率快速上升而证据命中率不再改善，则表明阈值已进入过保守区间，应予回调。该组指标同时是 5.3 节自适应阈值机制的在线反馈信号，并与第 4 章定义的无证据结论率与证据覆盖率形成对应关系——后者衡量离线能力上限，前者反映在线运行状态。

第 6 章 总结与展望

6.1 全文工作总结

本文针对大语言模型智能体在长程任务中暴露的三类结构性缺陷——上下文失配导致的约束稀释、缺乏证据锚点导致的幻觉传播、以及聚合依据不可靠导致的协作退化——提出了 CGA-Agent，一种面向结构化上下文与证据护栏的分层多智能体协同框架，并对其进行了形式化建模、实现与系统评估。

在方法层面，本文完成了四项工作。其一，将上下文从无类型文本序列重构为任务规范槽、证据槽、推理轨迹槽与长期记忆槽四类带类型槽位，并建立容量分配的最优化模型，以等边际条件刻画最优分配结构，为任务规范槽设置硬保留容量以抑制约束稀释。其二，提出以原子主张为最小可校验单元的 Claim-Evidence 证据护栏，通过主张抽取、证据绑定与覆盖度、蕴含度、可溯源三重闸门，把幻觉检测从事后整体评判推进到过程内逐条拦截，并自然产生可审计的校验轨迹。其三，设计基于信息增益与时间衰减联合评分的记忆写入门控，以双阈值规则抑制低价值写入与重复写入。其四，提出不确定性驱动的自适应规划与主张级一致性仲裁，以采样一致性的熵估计规避模型校准缺失问题，并以证据强度加权替代实例级置信度投票。

在实验层面，本文在 HotpotQA、StrategyQA、ToolBench 与自建数据集 CE-Bench 上，以三个随机种子对六个基线系统开展了主实验、消融实验、鲁棒性实验与稳定性分析。结果表明：CGA-Agent 的平均任务成功率达到 77.9%，较最强基线 AutoGen 提升 9.4 个百分点；证据覆盖率由 76.1% 提升至 91.7%，无证据结论率由 17.8% 降至 6.4%，误引用率降至 3.1%；平均 token 成本为 7.15 千 token，低于 AutoGen 的 13.2 千 token，在成本—性能平面上构成帕累托改进；在 50% 干扰文档注入条件下，性能衰减幅度约为基线的一半。消融实验确认证据护栏与结构化上下文为最关键模块，分别贡献 11.6 与 9.0 个百分点的成功率。

6.2 创新点凝练

本文的创新点可凝练为三句话。第一，把上下文从「文本拼接」升级为「带类型槽位的结构化资源」，并给出容量分配的最优性条件，使关键约束获得免于被稀释的结构性保障。第二，把幻觉治理从「事后评判」推进为「过程内逐条拦截」，以主张为最小校验单元、以证据绑定为强制环节，使系统输出的每一条结论都具备可独立复核的证明链，在降低无证据结论率的同时避免了成本膨胀。第三，把多智能体聚合从「实例级置信度投票」下沉为「主张级证据强度加权」，从机制上阻断了无证据的高置信主张主导结论的路径。三者的共同取向是：以显式的结构约束替代对模型自觉的依赖，使可信性成为可设计、可度量、可审计的系统属性。

6.3 未来研究展望

后续研究可从三个层面展开。在机制层面，将护栏由提示式串联改造为端到端可训练的判别模型，并探索证据源可信度的分层建模，以应对证据库自身被污染的对抗情形。在

效率层面，研究渐进式校验与自适应阈值，在保持误放行率上界的前提下压缩延迟与成本，使框架能够进入实时交互场景。在评估层面，构建覆盖多领域、带完整证据标注与对抗样本的标准化可信性基准，使不同技术路线能够在统一口径下比较其可信性收益与成本代价。此外，将本文的护栏思想推广至多模态智能体——使图像、音频等非文本主张同样具备证据绑定与可溯源能力——是一个具有较大探索空间的方向。

参考文献

- [1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.
- [2] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 1877-1901.
- [3] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022: 27730-27744.
- [4] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022: 24824-24837.
- [5] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[C]//International Conference on Learning Representations (ICLR). 2023.
- [6] ZHOU D, SCHÄRLI N, HOU L, et al. Least-to-most prompting enables complex reasoning in large language models[C]//International Conference on Learning Representations (ICLR). 2023.
- [7] YAO S, YU D, ZHAO J, et al. Tree of thoughts: Deliberate problem solving with large language models[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023: 11809-11822.
- [8] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing reasoning and acting in language models[C]//International Conference on Learning Representations (ICLR). 2023.
- [9] SHINN N, CASSANO F, BERMAN R, et al. Reflexion: Language agents with verbal reinforcement learning[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023: 8634-8652.
- [10] MADAAN A, TANDON N, GUPTA P, et al. Self-Refine: Iterative refinement with self-feedback[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023: 46534-46594.
- [11] SCHICK T, DWIVEDI-YU J, DESSÌ R, et al. Toolformer: Language models can teach themselves to use tools[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023: 68539-68551.
- [12] QIN Y, LIANG S, YE Y, et al. ToolLLM: Facilitating large language models to master 16000+ real-world APIs[C]//International Conference on Learning Representations (ICLR). 2024.
- [13] WU Q, BANSAL G, ZHANG J, et al. AutoGen: Enabling next-gen LLM applications via multi-agent conversation[J]. arXiv preprint arXiv:2308.08155, 2023.
- [14] HONG S, ZHUGE M, CHEN J, et al. MetaGPT: Meta programming for a multi-agent collaborative framework[C]//International Conference on Learning Representations (ICLR). 2024.
- [15] LI G, HAMMOUD H A K, ITANI H, et al. CAMEL: Communicative agents for “mind” exploration of large language model society[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023: 51991-52008.
- [16] PARK J S, O'BRIEN J C, CAI C J, et al. Generative agents: Interactive simulacra of human behavior[C]//Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST). 2023: 1-22.
- [17] DU Y, LI S, TORRALBA A, et al. Improving factuality and reasoning in language models through multiagent debate[C]//International Conference on Machine Learning (ICML). 2024: 11733-11763.
- [18] QIAN C, LIU W, LIU H, et al. ChatDev: Communicative agents for software development[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). 2024: 15174-15186.
- [19] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 9459-9474.
- [20] ASAI A, WU Z, WANG Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[C]//International Conference on Learning Representations (ICLR). 2024.
- [21] DHULIAWALA S, KOMARENKO O, XU L, et al. Chain-of-Verification reduces hallucination in large language models[C]//Findings of the Association for Computational Linguistics (ACL Findings). 2024: 3563-3578.
- [22] MANAKUL P, LIUSIE A, GALES M J F, et al. SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2023: 9004-9017.

- [23] LIU N F, LIN K, HEWITT J, et al. Lost in the middle: How language models use long contexts[J]. Transactions of the Association for Computational Linguistics (TACL), 2024, 12: 157-173.
- [24] PACKER C, WOODERS S, LIN K, et al. MemGPT: Towards LLMs as operating systems[J]. arXiv preprint arXiv:2310.08560, 2023.
- [25] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
- [26] WANG L, MA C, FENG X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.
- [27] XI Z, CHEN W, GUO X, et al. The rise and potential of large language model based agents: A survey[J]. Science China Information Sciences, 2025, 68(2): 121101.
- [28] LIU X, YU H, ZHANG H, et al. AgentBench: Evaluating LLMs as agents[C]//International Conference on Learning Representations (ICLR). 2024.
- [29] YANG Z, QI P, ZHANG S, et al. HotpotQA: A dataset for diverse, explainable multi-hop question answering[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2018: 2369-2380.
- [30] GEVA M, KHASHABI D, SEGAL E, et al. Did Aristotle use a laptop? A question answering benchmark with implicit reasoning strategies[J]. Transactions of the Association for Computational Linguistics (TACL), 2021, 9: 346-361.
- [31] GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023.
- [32] 王刚, 李明, 张宇. 大语言模型智能体的规划与工具调用研究综述[J]. 计算机学报, 2024, 47(8): 1701-1723.
- [33] 刘峰, 陈婧, 赵伟. 面向可信人工智能的大模型幻觉检测方法研究[J]. 软件学报, 2024, 35(6): 2711-2735.
- [34] 陈思远, 黄涛, 周志华. 多智能体协同的冲突消解与共识机制综述[J]. 自动化学报, 2023, 49(10): 2045-2062.
- [35] 杨帆, 杨强, 林海. 检索增强生成的证据一致性约束方法研究[J]. 计算机研究与发展, 2025, 62(1): 1-22.