

JiuwenSwarm v4: Agent 上下文工程

JiuwenSwarm/UCR 可审计科研半流程

1 重要边界

本文是 v4 LaTeX 源文件；配套正式 PDF 已由本机使用 XeLaTeX 编译。UCR 标签为 `process_evidence_only`，只能证明流程证据能力，不能包装成领域科学结论。claim-018 至 claim-020 及其绑定来源已批准正式引用，其余未批准来源仍排除。

2 研究问题与计划

问题：程序级证据护栏能否提高 Agent 执行报告的证据一致性？

假设：full-rail 应比无护栏或仅提示词减少无证据完成声明。

- 三个 arm 均 `status=completed` 且 `return_code=0`。
- UCR 在 full-rail 中低于 no-rail 与 prompt-only。
- full-rail 的 `rail.enabled=true` 且 `rail.accepted=true`。
- 所有 supported 决策均有 `matching_successful_evidence` 作为 reason。

3 方法

在相同任务集上运行 no-rail、prompt-only、full-rail 三个 arm，记录 `return_code`、`task_success_rate`、`rail` 状态与每个 `operation_id` 的 `decision.status / reason`。UCR 分母为全部完成声明，分子为无匹配证据的完成声明。实验结论仅引用本次记录；三条背景来源已单独批准正式引用。

3.1 实验设置

arm: no-rail (`rail.enabled=false`, `attempts=0`)、prompt-only (`rail.enabled=false`, `attempts=0`)、full-rail (`rail.enabled=true`, `attempts=1`, `accepted=true`)。三个 arm 均 `status=completed`、`return_code=0`。CFR 与 NFR 在 UCR 场景中均为 `not_measured_in_ucr_scenario`。

Arm	状态	UCR	Supported
no-rail	completed	0.5556	4
prompt-only	completed	0.0	4
full-rail	completed	0.0	4

4 实验结果

no-rail: UCR=0.5556 (5 / 9), supported=4, unexecuted=5, task_success_rate=1.0。prompt-only: UCR=0.0 (0 / 4), supported=4, unexecuted=0, task_success_rate=1.0。full-rail: UCR=0.0 (0 / 4), supported=4, unexecuted=0, task_success_rate=1.0, rail.enabled=true, attempts=1, accepted=true。所有 supported 决策的 reason 均为 matching_successful_evidence。

5 Claim–Evidence 账本

Claim ID	状态	类型
claim-001	supported	experiment_observation
claim-002	pending_human_review	experiment_observation
claim-003	pending_human_review	experiment_observation
claim-004	supported	experiment_observation
claim-005	pending_human_review	experiment_observation
claim-006	supported	experiment_observation
claim-007	pending_human_review	experiment_observation
claim-008	supported	experiment_observation
claim-009	pending_human_review	experiment_observation
claim-010	supported	experiment_observation
claim-011	supported	experiment_observation
claim-012	supported	experiment_observation
claim-013	supported	experiment_observation
claim-014	supported	experiment_observation
claim-015	supported	experiment_observation
claim-016	supported	experiment_observation
claim-017	supported	experiment_observation
claim-018	supported	background
claim-019	supported	background
claim-020	supported	background

6 检索资料与人工审批

候选资料数：10。只有人工批准后才允许正式引用。

Source ID	relevance review
crossref:10.2139 / ssrn.6506600	0.07 approved
crossref:10.37547 / taset / volume08issue03-12	0.07 approved
crossref:10.4018 / 978-1-60566-618-1.ch002	0.07 approved

Source ID	relevance	review
openalex:W3109746568	0.02	pending
openalex:W2165744313	0.02	pending
openalex:W2139457077	0.02	pending
openalex:W2153791616	0.02	pending
openalex:W2167554769	0.02	pending
openalex:W2124405605	0.02	pending
openalex:W2115421876	0.02	pending

7 限制

UCR 仅为 process_evidence_only 指标，不解释为任务质量或正确性。prompt-only 与 full-rail 的 UCR=0.0 可能因任务集不同而不可直接比较。no-rail 的 5 个 unexecuted 作为明确排除项。CFR 与 NFR 未在 UCR 场景中测量。仅批准的三条背景来源可正式引用，其余来源仍被排除。
不支持 Claim: claim-002, claim-003, claim-005, claim-007, claim-009

8 结论

在本次实验记录范围内，full-rail 的 UCR=0.0 低于 no-rail 的 0.5556，与 prompt-only 的 0.0 相同；full-rail 的 rail.enabled=true 且 accepted=true。该结果与假设方向一致，但因任务集差异与 UCR 指标限制，不能据此断言程序级护栏的因果效果。

9 人工确认

研究问题、实验真实性、结论范围和最终提交都需要人工确认。